Cookie

- 什么是cookie?
  - cookie的本质就是一组数据（键值对的形式存在）
  - 是由服务器创建，返回给客户端，最终会保存在客户端浏览器中。
  - 如果客户端保存了cookie，则下次再次访问该服务器，就会携带cookie进行网络访问。
    - 典型的案例：网站的免密登录
- 爬取雪球网中的咨询数据
  - url：https://xueqiu.com/，需求就是爬取热帖内容
  - 经过分析发现帖子的内容是通过ajax动态加载出来的，因此通过抓包工具，定位到ajax请求的数据包，从数据包中提取：
    - url：https://xueqiu.com/statuses/hot/listV2.json?since_id=-1&max_id=311519&size=15
    - 请求方式：get
    - 请求参数：拼接在了url后面

```
import requests
import os
headers = {
```

```
    'User-Agent':'Mozilla/5.0 (Macintosh;
Intel Mac OS X 10_15_7) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/98.0.4758.80
Safari/537.36',
}
url =
'https://xueqiu.com/statuses/hot/listV2.jso
n'
param = {
    "since_id": "-1",
    "max_id": "311519",
    "size": "15",
}
response =
requests.get(url=url,headers=headers,params
=param)
data = response.json()
print(data)
#发现没有拿到我们想要的数据
```

- 分析why?
  - 切记：只要爬虫拿不到你想要的数据，唯一的原因是爬虫程序模拟浏览器的力度不够！一般来讲，模拟的力度重点放置在请求头中！
  - 上述案例，只需要在请求头headers中添加cookie即可！

- 爬虫中cookie的处理方式（两种方式）：
  - 手动处理：将抓包工具中的cookie赋值到headers中即可
    - 缺点：
      - 编写麻烦
      - cookie通常都会存在有效时长
      - cookie中可能会存在实时变化的局部数据
  - 自动处理
    - 基于session对象实现自动处理cookie。
      - 1.创建一个空白的session对象。
      - 2.需要使用session对象发起请求，请求的目的是为了捕获cookie
        - 注意：如果session对象在发请求的过程中，服务器端产生了cookie，则cookie会自动存储在session对象中。
      - 3.使用携带cookie的session对象，对目的网址发起请求，就可以实现携带cookie的请求发送，从而获取想要的数据。
    - 注意：session对象至少需要发起两次请求
      - 第一次请求的目的是为了捕获存储cookie到session对象
      - 后次的请求，就是携带cookie发起的请求了

```
import requests
#1.创建一个空白的session对象
session = requests.Session()

headers = {
    'User-Agent':'Mozilla/5.0
(Macintosh; Intel Mac OS X 10_15_7)
AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/98.0.4758.80 Safari/537.36',
}
main_url = 'https://xueqiu.com/'
#2.使用session发起的请求，目的是为了捕获到
cookie，且将其存储到session对象中
session.get(url=main_url,headers=heade
rs)

url =
'https://xueqiu.com/statuses/hot/listV
2.json'
param = {
    "since_id": "-1",
    "max_id": "311519",
    "size": "15",
}
#3.就是使用携带了cookie的session对象发起的
请求（就是携带者cookie发起的请求）
```

```
response =
session.get(url=url,headers=headers,pa
rams=param)
data = response.json()
print(data)
```

- 获取https://passport.17k.com/中的书架页面里的图书信息

```
import requests

headers = {
    'User-Agent': 'Mozilla/5.0 (Windows NT
10.0; Win64; x64) AppleWebKit/537.36 (KHTML,
like Gecko) Chrome/109.0.0.0 Safari/537.36',
}

# 发送登陆处理接口的url地址
url = 'https://passport.17k.com/ck/user/login'
# 传递给服务器端的数据
data = {
    'loginName': '15027900535',
    'password': 'bobo328410948'
}
session = requests.Session()
session.post(url, headers=headers, data=data)
```

```
# 抓取登录后的数据:书架页面
# url = 'https://user.17k.com/www/bookshelf/'
#书架页面的图书信息
url = 'https://user.17k.com/ck/author/shelf?page=1&appKey=2406394919'
res = requests.get(url, headers=headers)

# 获取书架上的所有书籍
shelf_books = res.json()
print(shelf_books)
```

代理

- 什么是代理
  - 代理服务器
- 代理服务器的作用
  - 就是用来转发请求和响应

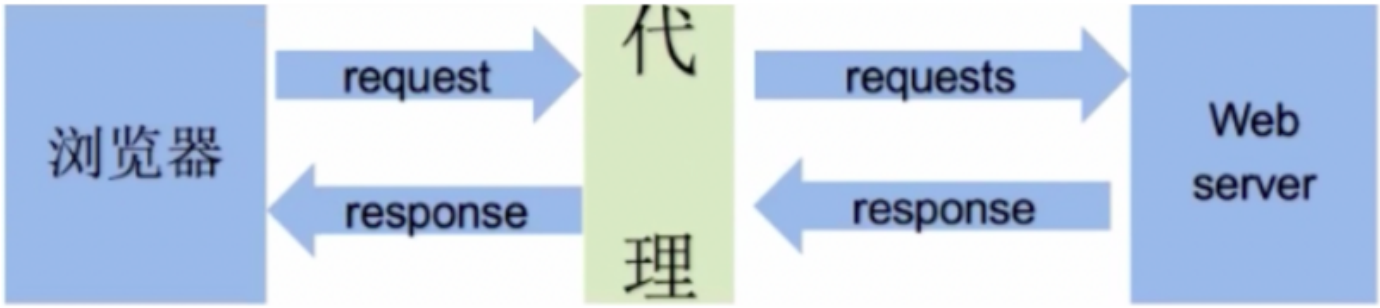

- 在爬虫中为何需要使用代理?
  - 有些时候，需要对网站服务器发起高频的请求，网站的服务器会检测到这样的异常现象，则会讲请求对应机器的ip地址加入黑名单，则该ip再次发起的请求，网站服务器就不在受理，则我们就无法再次爬取该网站的数据。
  - 使用代理后，网站服务器接收到的请求，最终是由代理服务器发起，网站服务器通过请求获取的ip就是代理服务器的ip，并不是我们客户端本身的ip。
- 代理的匿名度
  - 透明：网站的服务器知道你使用了代理，也知道你的真实ip
  - 匿名：网站服务器知道你使用了代理，但是无法获知你真实的ip
  - 高匿：网站服务器不知道你使用了代理，也不知道你的真实ip（推荐）
- 代理的类型（重要）
  - http：该类型的代理服务器只可以转发http协议的请求
  - https：可以转发https协议的请求
- 如何获取代理?
  - 芝麻代理：https://jahttp.zhimaruanjian.com/（推荐，有新人福利）
- 如何使用代理?

- 测试：访问如下网址，返回自己本机ip

```
import requests
from lxml import etree
headers = {
    'User-Agent':'Mozilla/5.0 (Macintosh;
Intel Mac OS X 10_15_7) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/98.0.4758.80
Safari/537.36',
}
url = 'http://www.cip.cc/'

page_text =
requests.get(url,headers=headers).text
tree = etree.HTML(page_text)
text =
tree.xpath('/html/body/div/div/div[3]/pre/t
ext()')[0]
print(text.split('\n')[0])
```

- 使用代理发起请求，查看是否可以返回代理服务器的ip

```
import requests
from lxml import etree
headers = {
    'User-Agent':'Mozilla/5.0 (Macintosh;
Intel Mac OS X 10_15_7) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/98.0.4758.80
Safari/537.36',
}
url = 'http://www.cip.cc/'

page_text =
requests.get(url,headers=headers,proxies=
{'http':'121.234.12.62:4246'}).text
tree = etree.HTML(page_text)
text =
tree.xpath('/html/body/div/div/div[3]/pre/t
ext()')[0]
print(text.split('\n')[0])
```

- 深度测试：
  - 对快代理进行n次请求，直到本机无法访问快代理为止（证明本机ip被快代理封掉了）
  - 构建一个代理池（封装了很多代理ip和端口的容器），用于数据的批量爬取

```
import requests
```

```
from lxml import etree
import random
headers = {
    'User-Agent':'Mozilla/5.0 (Macintosh;
Intel Mac OS X 10_15_7)
AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/98.0.4758.80 Safari/537.36',
}
#构建一个代理池
proxy_list = []
proxy_url =
'http://webapi.http.zhimacangku.com/getip
?
num=5&type=3&pro=&city=0&yys=0&port=1&pac
k=218090&ts=0&ys=0&cs=0&lb=1&sb=0&pb=4&mr
=1&regions='
page_text =
requests.get(url=proxy_url,headers=header
s).text
for ip in page_text.strip().split('\n'):
    dic = {}
    dic['https'] = ip.strip()
    proxy_list.append(dic)

for page in range(1,5001):
    print('正在爬取第%d页的ip数
据......'%page)
```

```
    url =
'https://www.kuaidaili.com/free/inha/%d/'
%page
    page_text =
requests.get(url=url,headers=headers,prox
ies=random.choice(proxy_list)).text
    tree = etree.HTML(page_text)
    tr_list = tree.xpath('//*
[@id="list"]/table/tbody/tr')
    for tr in tr_list:
        ip = tr.xpath('./td[1]/text()')
[0]
        print(ip)
```

验证码

- 图鉴平台：http://www.ttshitu.com/ （推荐）
- 使用图鉴识别古诗文网登录中的验证码
  - 古诗文网：https://so.gushiwen.cn/user/login.aspx?from=http://so.gushiwen.cn/user/collect.aspx
  - 使用流程：
    - 注册登录图鉴平台
    - 登录后，点击开发文档，提取识别的源代码
    - 模块(tujian.py)的封装：

```
import base64
import json
import requests
# 一、图片文字类型(默认 3 数英混合):
# 1 : 纯数字
# 1001: 纯数字2
# 2 : 纯英文
# 1002: 纯英文2
# 3 : 数英混合
# 1003: 数英混合2
#  4 : 闪动GIF
# 7 : 无感学习(独家)
# 11 : 计算题
# 1005:  快速计算题
# 16 : 汉字
# 32 : 通用文字识别(证件、单据)
# 66:  问答题
# 49 :recaptcha图片识别
# 二、图片旋转角度类型:
# 29 :  旋转类型
#
# 三、图片坐标点选类型:
# 19 :  1个坐标
# 20 :  3个坐标
# 21 :  3 ~ 5个坐标
# 22 :  5 ~ 8个坐标
```

```
# 27 :  1 ~ 4个坐标
# 48 : 轨迹类型
#
# 四、缺口识别
# 18 : 缺口识别（需要2张图 一张目标图一张缺口图)
# 33 : 单缺口识别（返回x轴坐标 只需要1张图）
# 五、拼图识别
# 53: 拼图识别
#函数实现忽略
def base64_api(uname, pwd, img, typeid):
    with open(img, 'rb') as f:
        base64_data =
base64.b64encode(f.read())
        b64 = base64_data.decode()
    data = {"username": uname,
"password": pwd, "typeid": typeid,
"image": b64}
    result =
json.loads(requests.post("http://api.ttsh
itu.com/predict", json=data).text)
    if result['success']:
        return result["data"]["result"]
    else:
        return result["message"]
    return ""
```

```
def getImgCodeText(imgPath,imgType):#直接返回验证码内容
    #imgPath: 验证码图片地址
    #imgType: 验证码图片类型
    result = base64_api(uname='bb328410948', pwd='bb328410948', img=imgPath, typeid=imgType)
    return result
```

- 验证码图片识别操作

```
from lxml import etree
import requests
import tujian
headers = {
    'User-Agent':'Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/97.0.4692.71 Safari/537.36'
}
#将验证码图片请求后保存到本地
```

```
login_url =
'https://so.gushiwen.cn/user/login.aspx?
from=http://so.gushiwen.cn/user/collect.a
spx'
page_text =
requests.get(url=login_url,headers=header
s).text
tree = etree.HTML(page_text)
img_src =
'https://so.gushiwen.cn'+tree.xpath('//*
[@id="imgCode"]/@src')[0]
code_data =
requests.get(url=img_src,headers=headers)
.content
with open('./code.jpg','wb') as fp:
    fp.write(code_data)

#识别验证码图片内容
result =
tujian.getImgCodeText('./code.jpg',3)
print(result)
```

模拟登录

- 古诗文网
- 在抓包工具里定位点击登录按钮后对应的数据包：

- 只要数据包的请求参数中包含用户名，密码和验证码则该数据包就是我们要定位的
- 首次模拟登录操作：

```
from lxml import etree
import requests
import tujian
headers = {
    'User-Agent':'Mozilla/5.0 (Macintosh;
Intel Mac OS X 10_15_7) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/97.0.4692.71
Safari/537.36'
}
#将验证码图片请求后保存到本地
login_url =
'https://so.gushiwen.cn/user/login.aspx?
from=http://so.gushiwen.cn/user/collect.asp
x'
page_text =
requests.get(url=login_url,headers=headers)
.text
tree = etree.HTML(page_text)
img_src =
'https://so.gushiwen.cn'+tree.xpath('//*
[@id="imgCode"]/@src')[0]
```

```
code_data =
requests.get(url=img_src,headers=headers).c
ontent
with open('./code.jpg','wb') as fp:
    fp.write(code_data)

#识别验证码图片内容
result =
tujian.getImgCodeText('./code.jpg',3)
print(result)
#模拟登录
url =
'https://so.gushiwen.cn/user/login.aspx?
from=http%3a%2f%2fso.gushiwen.cn%2fuser%2fc
ollect.aspx'
data = {
    "__VIEWSTATE":
"opfVI7oolwkr7MLRVzsNSMASqLRUuO1dg5ZP5EIRa4
FyM+mOYKEs6KWEKQKaba2ulLoZQIaLFiKK4mr5K3ci1
v8ua28wtcRtabKWjOtJtU/i2etH+zSduegTMcg=",
    "__VIEWSTATEGENERATOR": "C93BE1AE",
    "from":
"http://so.gushiwen.cn/user/collect.aspx",
    "email": "15027900535",
    "pwd": "bobo@15027900535",
    "code":result ,
    "denglu": "登录"
```

```
}
#获取了登录成功后的页面源码数据
login_page_text =
requests.post(url=url,headers=headers,data=
data).text
with open('wushiwen.html','w') as fp:
    fp.write(login_page_text)
```

- 查看gushiwen.html发现，没有登录成功，原因：
  - 验证码不对（否定）
  - 没有携带cookie
  - 出现了动态变化的请求参数
    - 如何获取动态变化的请求参数
      - 基于抓包工具进行全局搜索，发现该参数值被隐藏在了登录页面的页面源码中

```
from lxml import etree
import requests
import tujian
headers = {
    'User-Agent':'Mozilla/5.0 (Macintosh;
Intel Mac OS X 10_15_7)
AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/97.0.4692.71 Safari/537.36'
}
```

```
#创建session对象
session = requests.Session()

#将验证码图片请求后保存到本地
login_url =
'https://so.gushiwen.cn/user/login.aspx?
from=http://so.gushiwen.cn/user/collect.a
spx'
page_text =
session.get(url=login_url,headers=headers
).text
tree = etree.HTML(page_text)
img_src =
'https://so.gushiwen.cn'+tree.xpath('//*
[@id="imgCode"]/@src')[0]
code_data =
session.get(url=img_src,headers=headers).
content
with open('./code.jpg','wb') as fp:
    fp.write(code_data)

#解析出动态变化的请求参数
__VIEWSTATE = tree.xpath('//*
[@id="__VIEWSTATE"]/@value')[0]

#识别验证码图片内容
```

```
result =
tujian.getImgCodeText('./code.jpg',3)
print(result)
#模拟登录
url =
'https://so.gushiwen.cn/user/login.aspx?
from=http%3a%2f%2fso.gushiwen.cn%2fuser%2
fcollect.aspx'
data = {
    "__VIEWSTATE": __VIEWSTATE,
    "__VIEWSTATEGENERATOR": "C93BE1AE",
    "from":
"http://so.gushiwen.cn/user/collect.aspx"
,
    "email": "15027900535",
    "pwd": "bobo@15027900535",
    "code":result ,
    "denglu": "登录"
}
#获取了登录成功后的页面源码数据
login_page_text =
session.post(url=url,headers=headers,data
=data).text
with open('wushiwen.html','w') as fp:
    fp.write(login_page_text)
```

防盗链

- 现在很多网站启用了防盗链反爬，防止服务器上的资源被人恶意盗取。什么是防盗链呢?
  - 以图片为例，访问图片要从他的网站访问才可以，否则直接访问图片地址得不到图片
- 练习：抓取微博图片，url：http://blog.sina.com.cn/lm/pic/，将页面中某一组系列详情页的图片进行抓取保存，比如三里屯时尚女郎：http://blog.sina.com.cn/s/blog_01ebcb8a0102zi2o.html?tj=1
  - 注意：
    - 1.在解析图片地址的时候，定位src的属性值，返回的内容和开发工具Element中看到的不一样，通过network查看网页源码发现需要解析real_src的值。
    - 2.直接请求real_src请求到的图片不显示，加上Refere请求头即可
      - 哪里找Refere：抓包工具定位到某一张图片数据包，在其requests headers中获取

```
import requests
from lxml import etree
headers = {
```

```
    'User-Agent':'Mozilla/5.0 (Macintosh;
Intel Mac OS X 10_15_7)
AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/97.0.4692.71 Safari/537.36',
    "Referer":
"http://blog.sina.com.cn/",

}
url =
'http://blog.sina.com.cn/s/blog_01ebcb8a0
102zi2o.html?tj=1'
page_text =
requests.get(url,headers=headers).text
tree = etree.HTML(page_text)
img_src = tree.xpath('//*
[@id="sina_keyword_ad_area2"]/div/a/img/@
real_src')
for src in img_src:
    data =
requests.get(src,headers=headers).content
    with open('./123.jpg','wb') as fp:
        fp.write(data)
    # break
```

图片懒加载(作业)

- url：https://sc.chinaz.com/tupian/meinvtupian.html
- 爬取上述链接中所有的图片数据
- 图片懒加载：
  - 主要是应用在展示图片的网页中的一种技术，该技术是指当网页刷新后，先加载局部的几张图片数据即可，随着用户滑动滚轮，当图片被显示在浏览器的可视化区域范围的话，在动态将其图片请求加载出来即可。（图片数据是动态加载出来）。
  - 如何实现图片懒加载/动态加载?
    - 使用img标签的伪属性（指的是自定义的一种属性）。在网页中，为了防止图片马上加载出来，则在img标签中可以使用一种伪属性来存储图片的链接，而不是使用真正的src属性值来存储图片链接。（图片链接一旦给了src属性，则图片会被立即加载出来）。只有当图片被滑动到浏览器可视化区域范围的时候，在通过js将img的伪属性修改为真正的src属性，则图片就会被加载出来。
- 如何爬取图片懒加载的图片数据?
  - 只需要在解析图片的时候，定位伪属性（src2）的属性值即可。